Министерство науки и высшего образования Российской Федерации
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ ИТМО
ITMO University

Лабораторная работа №1*

По дисциплине Современные методы искусственного интеллекта

Тема работы Классификация изображений с применением transfer learning

Обучающийся Сакулин Иван Михайлович

Факультет Факультет прикладной информатики

Группа K3321

Направление подготовки 11.03.02 Инфокоммуникационные технологии и системы связи

Образовательная программа Программирование в инфокоммуникационных системах

Обучающийся	_____	_____	Сакулин И.М.
	(дата)	(подпись)	(Ф.И.О.)
Руководитель	_____	_____	Царёв Д.В.
	(дата)	(подпись)	(Ф.И.О.)

2026

СОДЕРЖАНИЕ

Стр.

ВВЕДЕНИЕ **3**

1 ИСПОЛЬЗОВАНИЕ ПРЕДОБУЧЕННЫХ НЕЙРОСЕТЕЙ ... **4**

1.1 Выбор датасета Oxford-IIIT Pet 4
1.2 Выбор архитектуры ResNet18 4
1.3 Подготовка данных 5
1.3.1 Предварительная обработка изображений 5
1.3.2 Разделение датасета 6
1.3.3 Загрузка данных 6
1.4 Feature Extraction 7
1.4.1 Настройка модели 7
1.4.2 Обучение модели 7
1.4.3 Оценка модели 9
1.5 Fine-tuning 10
1.5.1 Настройка модели 10
1.5.2 Обучение модели 11
1.5.3 Оценка модели 13
1.6 Сравнение 14

ЗАКЛЮЧЕНИЕ **16**

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ **17**

ВВЕДЕНИЕ

Цель работы — сформировать навыки использования предобученных нейросетевых архитектур для решения задач компьютерного зрения на специфических наборах данных.

Задачи работы:

- выбрать датасет для задачи классификации изображений (не менее трёх классов);
- выбрать предобученную архитектуру ResNet, EfficientNet или MobileNet и обосновать выбор;
- реализовать стратегию Feature Extraction: заморозить веса базовой сети, заменить выходной слой и обучить модель;
- оценить качество классификации и построить матрицу ошибок;
- реализовать стратегию Fine-tuning: разморозить часть верхних слоёв базовой сети и провести дообучение с низким темпом обучения;
- сравнить результаты двух подходов по метрикам Accuracy, Precision и Recall и сделать вывод о целесообразности дообучения весов базовой сети.

Все программы, обсуждаемые в работе, доступны в репозитории [1].

1 ИСПОЛЬЗОВАНИЕ ПРЕДОБУЧЕННЫХ НЕЙРОСЕТЕЙ

1.1 Выбор датасета Oxford-IIIT Pet

Для работы был выбран датасет `Oxford-IIIT Pet`. Датасет содержит изображения домашних животных, распределённые по 37 классам, соответствующим различным породам кошек и собак. Выбор обусловлен личными предпочтениями автора и разнообразием изображений: объекты имеют различный фон, положение и масштаб [2]. Пример изображений на рисунке 1.

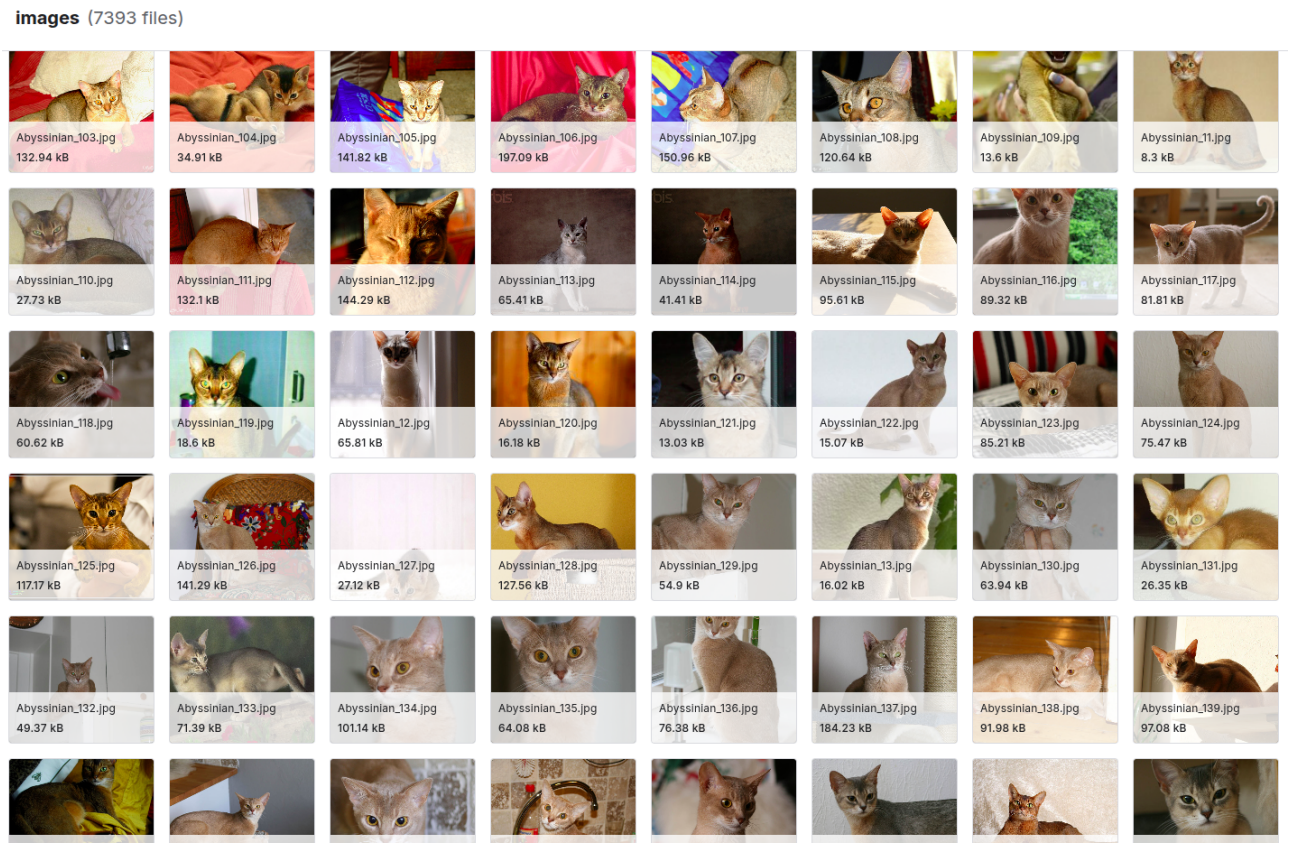


Рисунок 1 — Примеры изображений из датасета Oxford-IIIT Pet

1.2 Выбор архитектуры ResNet18

ResNet выбрана как компромисс между качеством классификации и вычислительной сложностью: основное преимущество MobileNet – работа в ограниченных ресурсах, EfficientNet может быть точнее, но имеет более сложную архитектуру.

ResNet является сверточной нейросетью для классификации изображений, 18 версия была выбрана для уменьшения необходимых вычислительных мощностей. Веса модели предварительно обучены на ImageNet, а последний классификационный слой заменяется на слой с 37 выходами.

1.3 Подготовка данных

1.3.1 Предварительная обработка изображений

Для всех изображений выполняются следующие преобразования, которые необходимы для соответствия объектов датасета объектам формату входных данных предобученной ResNet18:

- изменение размера изображения до 224×224 пикселей;
- нормализация цветовых каналов;
- преобразование изображения в тензор.

Чтобы увеличить разнообразие обучающих данных и улучшить обобщающую способность модели, для тренировочной выборки дополнительно применяются следующие аугментации, пример на рисунке 2:

- случайное горизонтальное отражение изображения;
- случайный поворот изображения на угол до $\pm 10°$.

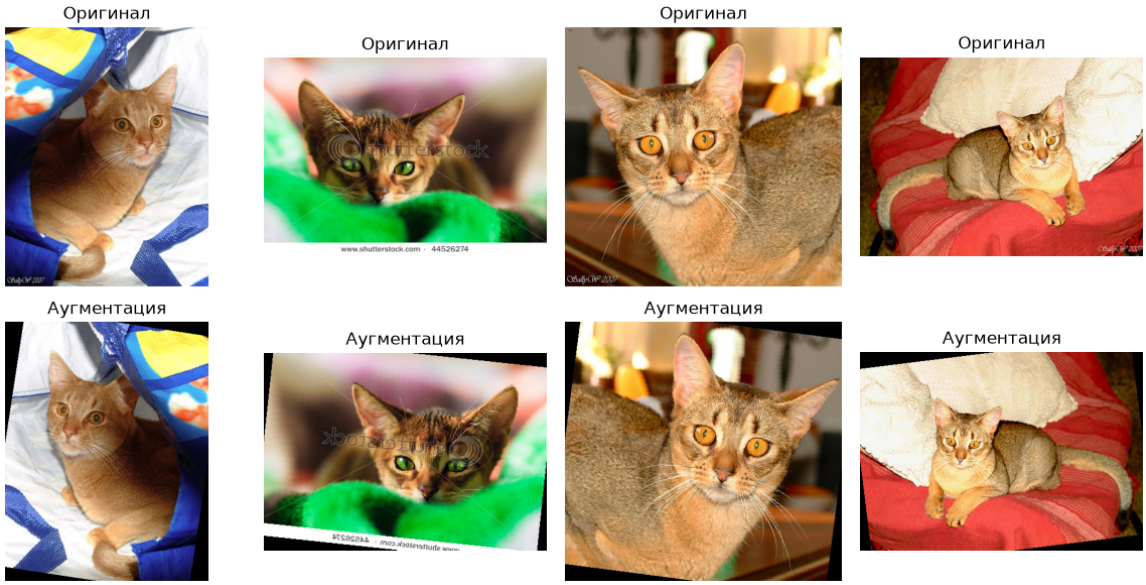


Рисунок 2 — Примеры аугментации изображений

1.3.2 Разделение датасета

Основной датасет разделяется на тренировочную и валидационную выборки в соотношении 80/20. В результате получены (рисунок 3):

- тренировочная выборка — 2944 изображения;
- валидационная выборка — 736 изображений;
- тестовая выборка — 3669 изображений.

```
Train: 2944
Validation: 736
Test: 3669
```

Рисунок 3 — Размеры датасетов после разделения

1.3.3 Загрузка данных

Для пакетной передачи данных используются объекты `DataLoader`. Размер пакета составляет 32 изображения. Для тренировочной выборки используется перемешивание данных. Итоговые параметры получившихся пакетов данных на рисунке 4.

```
Images:
        batch_size=32
        color_channels=3
        width=224
        height=224
Labels:
        batch_size=32
```

Рисунок 4 — Параметры пакетов данных

1.4 Feature Extraction

1.4.1 Настройка модели

Для первого подхода нужно у существующей модели (натренированной на ImageNet) заморозить все слои, чтобы их нельзя было переобучить, и заменить итоговый классификатор на подходящий для выбранного датасета на 37 класссов (рисунок 5).

```
weights = ResNet18_Weights.DEFAULT
model = models.resnet18(weights=weights)

# Замораживаем все параметры предобученной сети
for param in model.parameters():
    param.requires_grad = False

# Заменяем последний классификатор на 37 классов
model.fc = nn.Linear(model.fc.in_features, len(class_names))

# Переносим модель на GPU
model = model.to(device)
```

Рисунок 5 — Настройка модели (Feature Extraction)

1.4.2 Обучение модели

Обучение модели проводилось в течение 10 эпох с использованием функции потерь `CrossEntropyLoss` (сравнивает предсказанные моделью вероятности классов с правильной меткой класса) и оптимизатора `Adam` (автоматически адаптирует шаг обучения для каждого параметра). Скорость обучения (насколько сильно модель изменяет свои веса после одной ошибки) была установлена равной 0,001.

В процессе обучения после каждой эпохи рассчитывалась точность на тренировочной и валидационной выборках (рисунок 6) и величина функции

потерь (рисунок 7). Для дальнейшей оценки сохранялись веса модели, показавшей наилучший результат на валидационной выборке. Наилучшее значение точности на валидационной выборке составило $87,36\%$ и было получено на восьмой эпохе.

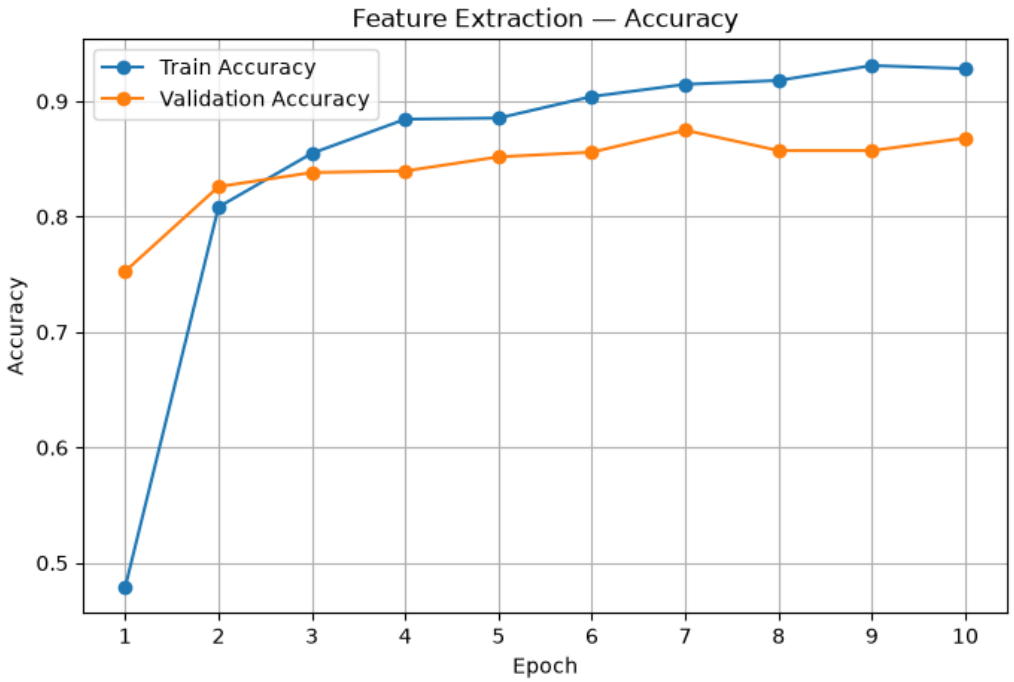


Рисунок 6 — Изменение Accuracy в процессе обучения Feature Extraction

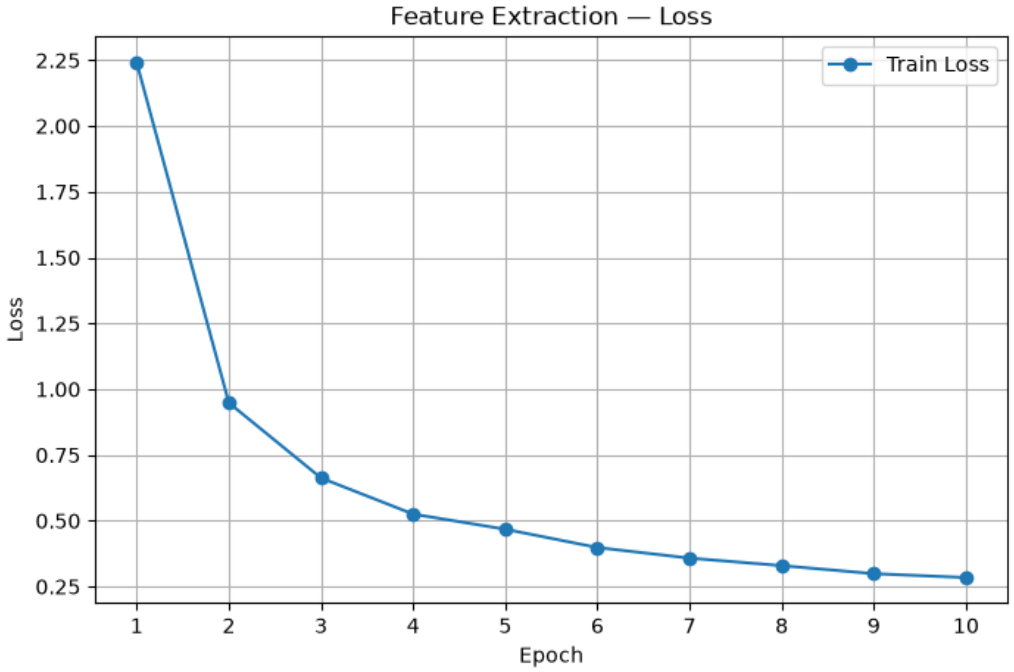


Рисунок 7 — Изменение функции потерь в процессе обучения Feature Extraction

1.4.3 Оценка модели

Результаты оценки модели Feature Extraction на тестовой выборке представлены в таблице 1. Матрица ошибок представлена на рисунке 8.

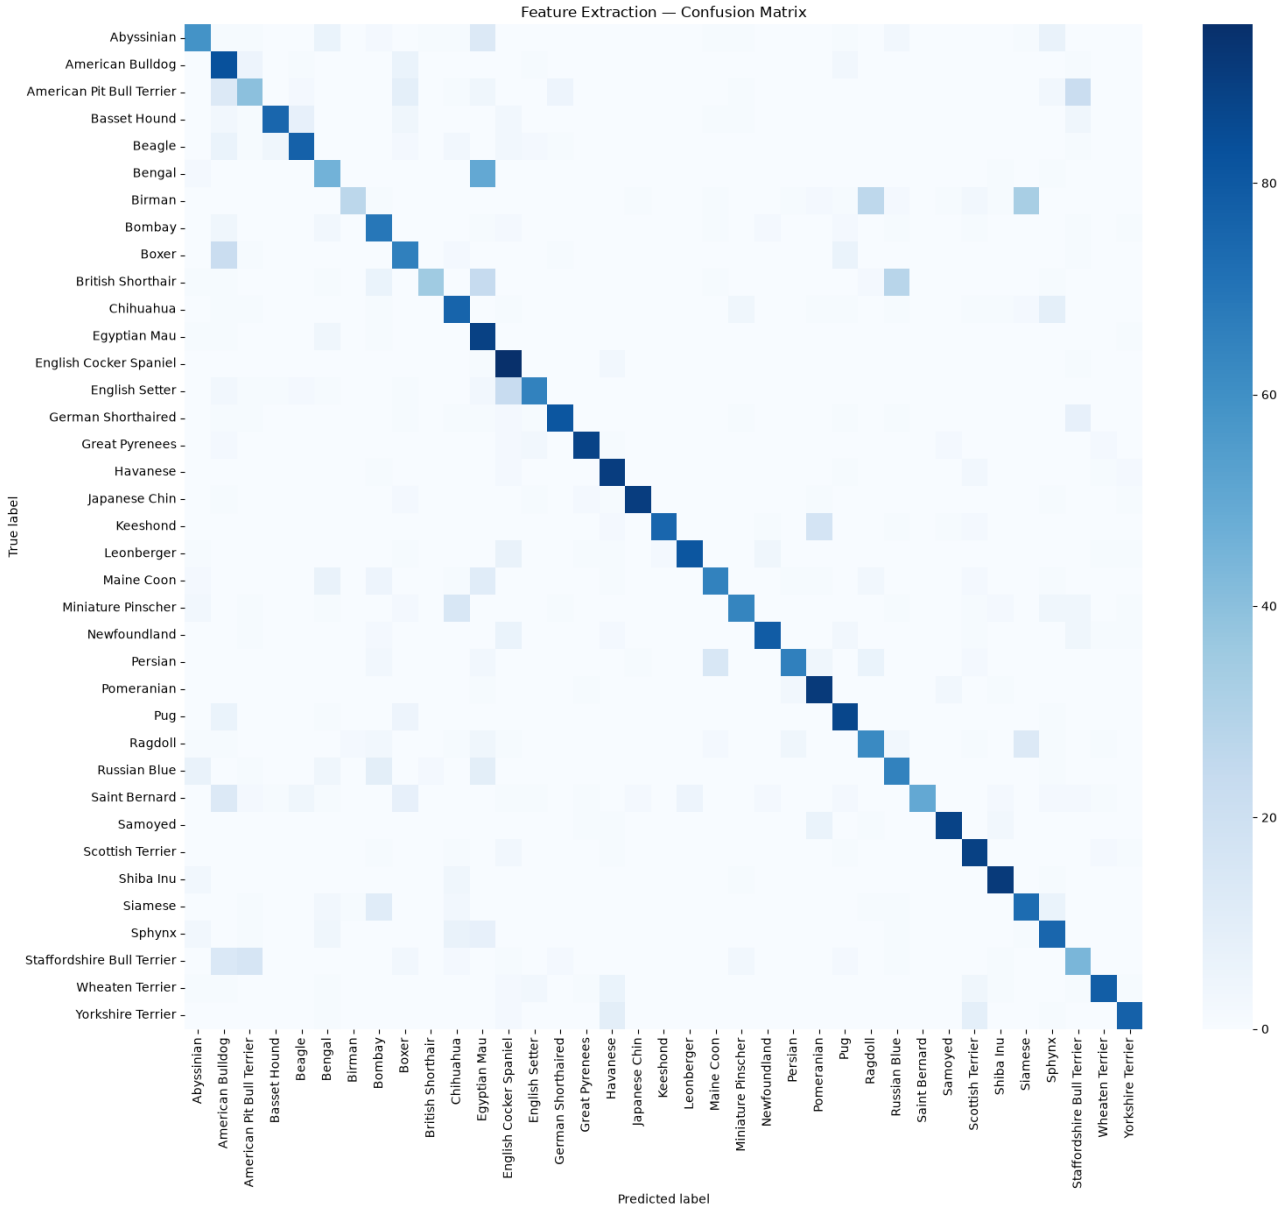


Рисунок 8 — Матрица ошибок модели Feature Extraction

Таблица 1 — Результаты Feature Extraction на тестовой выборке

Метрика	Значение
Accuracy	0.7225
Precision	0.7595
Recall	0.7222
F1-score	0.7210

Полученные результаты показывают, что модель правильно классифицирует большую часть изображений тестовой выборки. Значение Precision немного выше Recall, что указывает на несколько более высокую точность предсказаний отдельных классов по сравнению с полнотой их распознавания.

1.5 Fine-tuning

1.5.1 Настройка модели

Для второго подхода в отличие от Feature Extraction, часть слоёв модели размораживается для их дальнейшего дообучения на выбранном датасете. В работе размораживается последний остаточный блок `layer4`, а остальные слои остаются замороженными. Итоговый классификатор заменяется на новый слой с 37 выходами, соответствующими классам датасета (рисунок 9).

```
weights = ResNet18_Weights.DEFAULT
model_ft = models.resnet18(weights=weights)

# Замораживаем всю предобученную сеть
for param in model_ft.parameters():
param.requires_grad = False

# Размораживаем последний residual block
for param in model_ft.layer4.parameters():
param.requires_grad = True

# Заменяем классификатор на 37 классов
model_ft.fc = nn.Linear(
model_ft.fc.in_features,
len(class_names)
)

# Переносим модель на GPU
model_ft = model_ft.to(device)
```

Рисунок 9 — Настройка модели (Fine-tuning)

1.5.2 Обучение модели

Обучение модели проводилось в течение 10 эпох с использованием функции потерь `CrossEntropyLoss` и оптимизатора `Adam`. Скорость обучения была установлена равной 0,0001. Меньшая скорость обучения по сравнению с Feature Extraction используется для более осторожного изменения уже предобученных весов последнего блока сети.

В процессе обучения после каждой эпохи рассчитывалась точность на тренировочной и валидационной выборках (рисунок 10), а также величина функции потерь (рисунок 11). Для дальнейшей оценки сохранялись веса модели, показавшей наилучший результат на валидационной выборке. Наилуч-

шее значение точности на валидационной выборке составило $90,62\%$ и было получено на девятой эпохе.

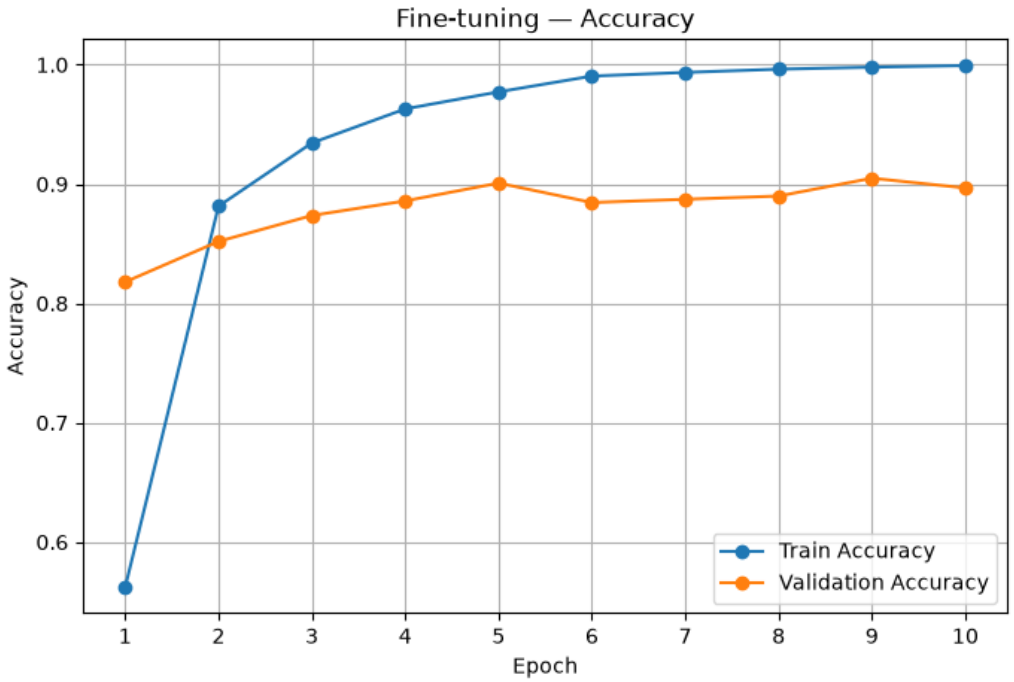


Рисунок 10 — Изменение Accuracy в процессе обучения Fine-tuning

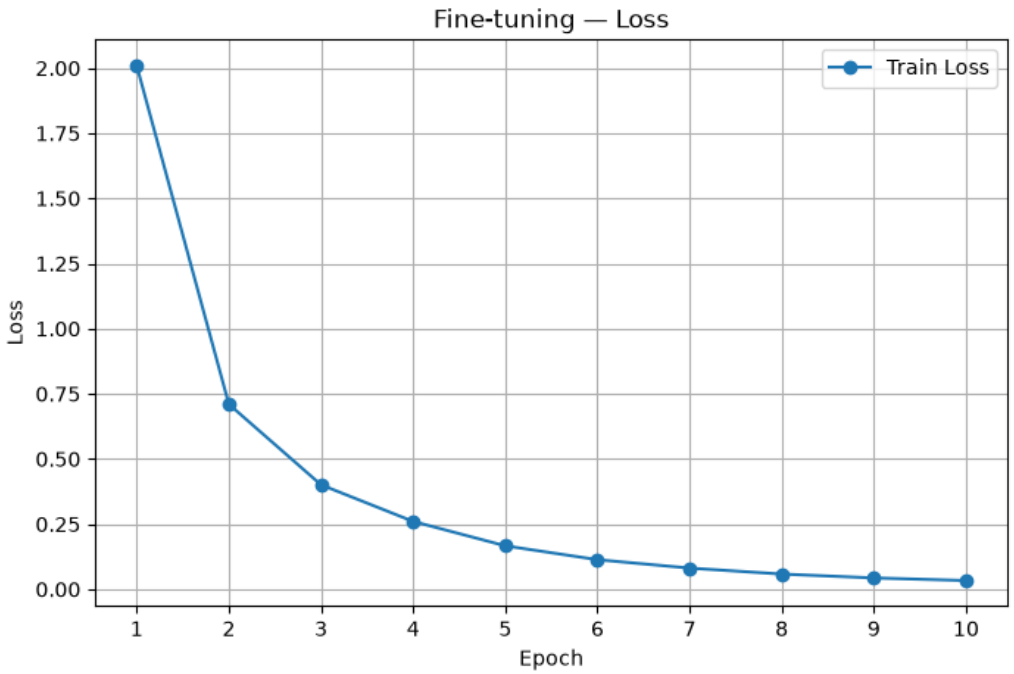


Рисунок 11 — Изменение функции потерь в процессе обучения Fine-tuning

1.5.3 Оценка модели

Результаты оценки модели Fine-tuning на тестовой выборке представлены в таблице 2. Матрица ошибок представлена на рисунке 12.

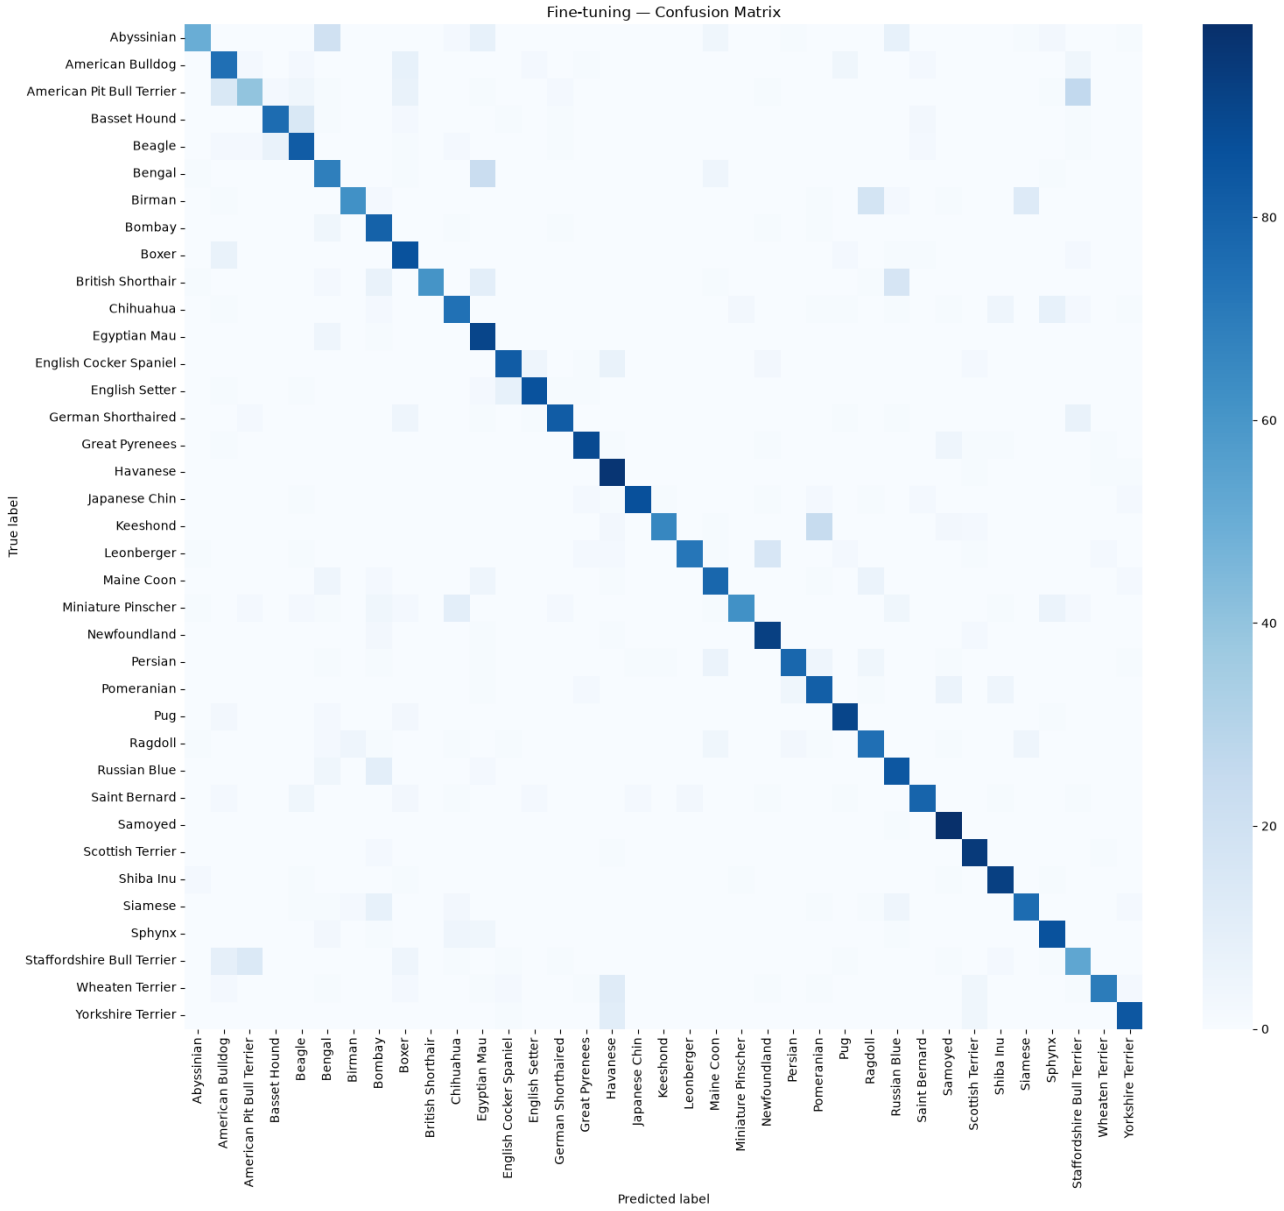


Рисунок 12 — Матрица ошибок модели Fine-tuning

Таблица 2 — Результаты Fine-tuning на тестовой выборке

Метрика	Значение
Accuracy	0.7860
Precision	0.8044
Recall	0.7859
F1-score	0.7842

Полученные результаты показывают, что после дообучения последнего блока модели удалось получить достаточно высокие значения основных метрик классификации. Значение Precision составило $80,44\%$, а Recall — $78,59\%$.

1.6 Сравнение

Сравнение метрик Feature Extraction и Fine-tuning на тестовой выборке представлено на рисунке 13 и в таблице 3.

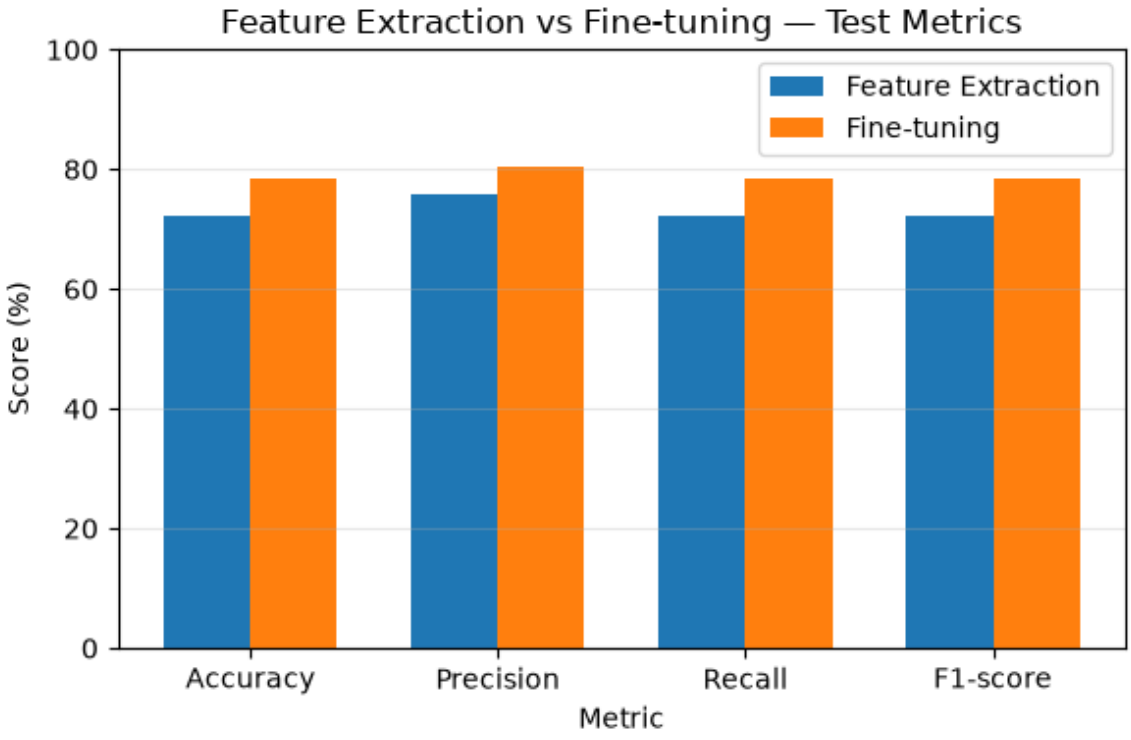


Рисунок 13 — Сравнение метрик Feature Extraction и Fine-tuning

Таблица 3 — Итоговое сравнение результатов на тестовой выборке

Метрика	Feature Extraction	Fine-tuning	Изменение
Accuracy	72,25%	78,60%	+6,35 п.п.
Precision	75,95%	80,44%	+4,49 п.п.
Recall	72,22%	78,59%	+6,37 п.п.
F1-score	72,10%	78,42%	+6,32 п.п.

По результатам работы было установлено, что переобучение части базовой модели увеличило все метрики в среднем на 6%: количество правильных предсказаний, их точность и полноту.

Таким образом, Fine-tuning оказался более эффективным подходом для рассматриваемой задачи. Дообучение верхнего блока предобученной сети позволило адаптировать сформированные признаки под особенности изображений пород кошек и собак, что привело к увеличению качества классификации. Поэтому для данного датасета применение Fine-tuning является целесообразным.

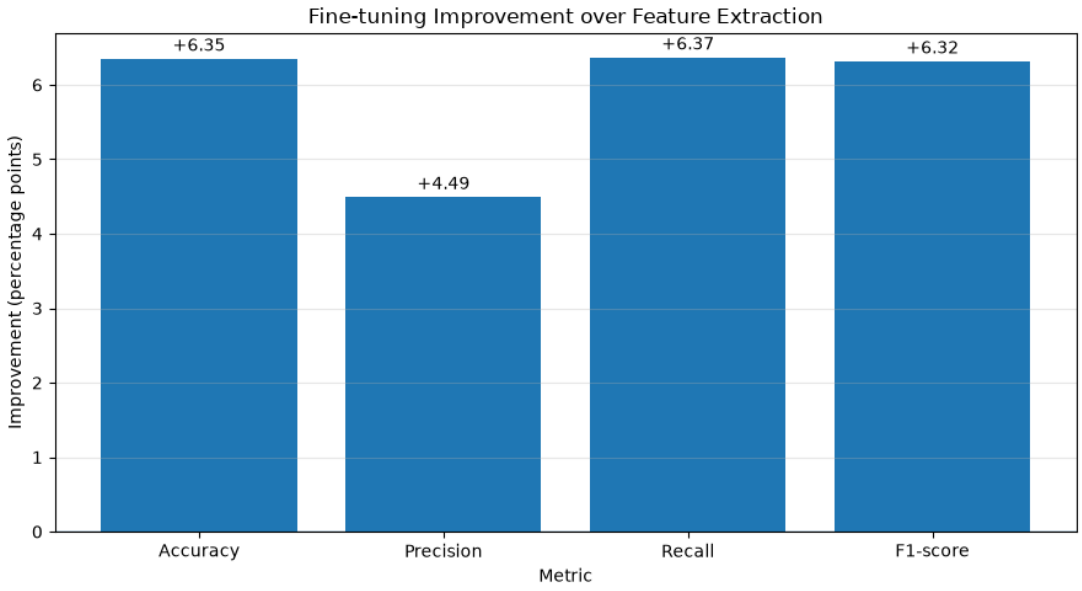


Рисунок 14 — Изменение метрик при переходе к Fine-tuning

ЗАКЛЮЧЕНИЕ

В ходе работы были реализованы стратегии Feature Extraction и Fine-tuning для классификации изображений датасета Oxford-IIIT Pet с использованием предобученной архитектуры ResNet18.

В результате Feature Extraction была получена Accuracy $72,25\%$, тогда как применение Fine-tuning позволило повысить её до $78,60\%$. Также увеличились значения Precision, Recall и F1-score. Таким образом, Fine-tuning показал более высокие результаты по всем рассмотренным метрикам.

По результатам работы было установлено, что дообучение верхних слоёв предобученной модели позволяет улучшить качество классификации. Поэтому для рассматриваемого датасета применение Fine-tuning является целесообразным.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Исходный код работы [Электронный ресурс]. — URL: https://github.com/OneTwoZzzPlus/modern-ai-methods/ (дата обращения: 04.10.2026).

2. The Oxford-IIIT Pet Dataset [Электронный ресурс]. — URL: https://www.kaggle.com/datasets/tanlikesmath/the-oxfordiiit-pet-dataset (дата обращения: 04.10.2026).